ESCUELA DE
INGENIERÍA INFORMÁTICA



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

PROGRAMACIÓN DE CIRUGÍAS ELECTIVAS MEDIANTE BÚSQUEDA TABÚ Y SELECCIÓN ADAPTATIVA DE MOVIMIENTOS

José Basualto

Cristopher Dauros

Carlos Ruz

Segundo informe

OII464: Desarrollo de Diseños Híbridos para Optimización

2 de noviembre de 2026

RESUMEN

La programación de cirugías electivas exige coordinar las etapas de anestesia y cirugía, considerando la disponibilidad compartida de salas y profesionales para evitar que la espera entre procedimientos prolongue la jornada o bloquee recursos. Para abordar este problema, se propone integrar búsqueda tabú con un bandido multibrazo dinámico (D-MAB), que aprende durante la ejecución qué movimientos conviene utilizar y orienta así la generación de vecinos en la evolución de la búsqueda. La metodología incorpora una cartera con dos trayectorias, una de selección uniforme y otra guiada por D-MAB, que comparten un presupuesto total de evaluaciones y conservan el mejor calendario factible, respetando las restricciones de recursos y espera máxima. Su evaluación se realizará en instancias sintéticas mediante comparaciones y ablaciones con igual presupuesto, considerando calidad, bloqueo, tiempo y robustez para distinguir el aporte del aprendizaje del efecto de repetir la búsqueda. Con este diseño se busca identificar las condiciones en que la adaptación puede aportar mejoras reproducibles y determinar si estas justifican su costo computacional.

Palabras clave: programación de cirugías; búsqueda tabú; selección adaptativa de operadores; aprendizaje en línea; bloqueo.

1. Introducción

Organizar una jornada quirúrgica supone distribuir una capacidad limitada entre pacientes cuyas intervenciones tienen distintas duraciones y requerimientos. La disponibilidad de quirófanos y personal especializado, así como los tiempos de preparación y limpieza, condiciona tanto el orden de atención como el término de la jornada. Cuando la anestesia y la cirugía se realizan en etapas distintas, la espera por la segunda sala puede retener la primera y su profesional, prolongando la jornada y dificultando el uso de los recursos. En el problema considerado, se busca reducir el makespan, entendido como el tiempo de término de la última operación, y el bloqueo, respetando la precedencia, la espera máxima y la disponibilidad (Lara Arce, 2026). A diferencia de la suma de duraciones fijas, el makespan depende de cómo se ordenan los pacientes y se asignan los recursos.

La literatura distingue roles del aprendizaje: Akbarzadeh y Maenhout (2024) predicen factibilidad en secuencias quirúrgicas multifase; Niroumandrad et al. (2024) orientan Tabu con clasificadores para programar médicos. En selección de operadores, Yu et al. (2024) emplean Q-learning en programación y reprogramación quirúrgica, y el preprint de Dolatkhah et al. (2026) usa D-MAB dentro de un algoritmo genético para generar columnas iniciales. Yin et al. (2026) aportan Tabu iterado multioperador entre hospitales, mientras DaCosta et al. (2008) constituyen el fundamento histórico de D-MAB. Difieren en representación, restricciones y evaluación; queda por establecer el aporte de D-MAB al Tabu del caso docente de dos etapas con espera estricta, reparación y controles de cómputo.

El objetivo de este proyecto es estudiar si la selección adaptativa de movimientos puede mejorar la calidad, el tiempo o la robustez de Tabu Search frente a la selección uniforme, integrando una metaheurística (MH) con aprendizaje automático (ML). Para ello, D-MAB orientará la generación de vecinos durante la *evolución* de la trayectoria (Vega, s.f.), y su aporte se evaluará con instancias sintéticas del repositorio oficial (Saicooh, 2026), mediante comparaciones con las mismas restricciones y presupuestos de búsqueda equivalentes.

2. Propuesta metodológica

2.1. Problema, representación y factibilidad

La agenda será estática, con duraciones conocidas. La solución fija orden y salas independientes por etapa; el planificador asigna profesionales elegibles disponibles. La espera y el fin de jornada son

$$W_j = \max\{0, T_j^C - F_j^A\}, \qquad 0 \le W_j \le L_j, \qquad C_{\max} = \max_{j \in J} F_j^C. \tag{1}$$

J es el conjunto de pacientes y j un paciente; T_j^C es el inicio de cirugía; F_j^A y F_j^C son los fines de cada etapa, incluida limpieza; W_j es la espera; L_j su límite estricto, y $C_{\max}$ el makespan. Las reservas siguen el modelo docente; la primera sala permanece ocupada hasta el traslado si las salas difieren.

Se minimizará el siguiente criterio, sin penalización por desequilibrio de salas:

$$f(S) = C_{\max} + 10^{-6} \sum_{o} t_o^{\text{ini}} + 0{,}5 \sum_{j \in J} W_j + 1{,}4 \max_{j \in J} W_j. \tag{2}$$

S es un calendario y $f(S)$ su objetivo; o recorre las operaciones y t_o^{ini} es su inicio de reserva. $C_{\max}$, J y W_j se definieron en (1). El coeficiente 10^{-6} desempata; $0{,}5$ y $1{,}4$ ponderan espera total y máxima. Se reportarán estas métricas por separado: una reducción de f no equivale necesariamente a la misma reducción del makespan.

Las claves aleatorias representan orden y salas. El decodificador pospone pacientes no programables y repara asignaciones. La reparación puede alterar el movimiento y restringir calendarios alcanzables; se registrará su efecto sobre la atribución de recompensas.

2.2. Componente MH: búsqueda tabú

Tabu parte de la mejor de treinta soluciones: FIFO (orden original), SPT y LPT (duración total creciente y decreciente) y veintisiete aleatorias. Propone intercambio, inserción y cambio de sala de anestesia, cirugía o ambas. Explora lotes de quince candidatos, priorizando pacientes con espera. Recuerda siete soluciones, con aspiración por mejora global; si ninguna es admisible, usa la mejor del lote. Puede aceptar empeoramientos locales y conserva el mejor resultado global.

2.3. Componente ML: selección adaptativa en la evolución

D-MAB elige el movimiento de cada candidato; cada operador es un brazo. UCB1 combina recompensa media y exploración de brazos menos probados. Page–Hinkley detecta caídas y reinicia estimaciones, conservando Tabu; es una prueba estadística del controlador (DaCosta et al., 2008). La recompensa es la mejora positiva del candidato reparado frente al estado local del lote, normalizada en $[0, 1]$; los duplicados reciben cero sin consumir evaluación. Se aprende durante la corrida, sin entrenamiento previo. ML decide qué vecinos proponer en la evolución de la trayectoria; el planificador asegura factibilidad y Tabu selecciona el vecino aceptado.

2.4. Orquestación y cartera con respaldo

Fuera de línea se prepararán instancias y calibrarán parámetros con datos exploratorios separados. En línea se generarán, repararán y evaluarán candidatos, actualizando Tabu y D-MAB. Se partirá de exploración $C = 0{,}1$, umbral Page–Hinkley $\lambda = 1$ y margen del detector $\delta = 0{,}01$; estos parámetros se revisarán en desarrollo.

La cartera inicial ejecuta secuencialmente Tabu uniforme y Tabu con D-MAB, cada uno con 3.030 evaluaciones, incluidas sus treinta inicializaciones. Ambos comparten instancia, semilla y configuración inicial, pero mantienen memorias y trayectorias independientes. Se devuelve el mejor calendario factible de los dos. El criterio de parada suma 6.060 evaluaciones; la comprobación final del calendario se registra aparte del presupuesto de búsqueda.

El reparto 50/50 es fijo y no aprende qué camino ganará. Conserva el objetivo de Tabu de 3.030 evaluaciones, sin garantizar superar a Tabu de 6.060. La entrada ejecutable guarda ambos caminos y el calendario elegido.

2.5. Datos, controles y plan de evaluación

Se trabajará con 12 instancias obtenidas del repositorio oficial del problema a estudiar, correspondientes a tres réplicas de 15, 20, 25 y 30 cirugías. Se comprobarán esquema, hashes, elegibilidad y unidades temporales. El tamaño, los recursos, las duraciones y la espera permitida son metacaracterísticas descriptivas; no son entradas contextuales de D-MAB. Las nuevas semillas no sustituyen una evaluación en instancias reservadas. Durante el semestre se incorporarán escenarios de mayor congestión y tamaños de 50, 100 y 150 cirugías, ajustando recursos y declarando su procedencia sintética.

Tabla 1: Controles y ablaciones para identificar el aporte del aprendizaje.

Comparación	Propósito
FIFO, SPT y LPT	Referencias constructivas; también inicializan la búsqueda.
Tabu uniforme	Medir el efecto de aprender con los mismos movimientos.
Dos Tabu uniformes	Separar aprendizaje de diversidad por repetir la búsqueda.
Tabu con D-MAB	Aislar el camino aprendido frente a la cartera completa.
UCB1 sin detector	Ablación del reinicio Page–Hinkley.

Se medirán objetivo, makespan, espera total y máxima, factibilidad, tiempo y convergencia; la robustez se estimará entre semillas. Se emparejarán instancias y semillas, con presupuestos de evaluaciones iguales entre estrategias y, en pruebas separadas, igual tiempo máximo. La incertidumbre se agrupará por instancia, con contrastes corregidos por comparaciones múltiples.

Se emplearán datos sintéticos sin identificadores clínicos y se registrarán el equipo, la configuración y el tiempo de ejecución de cada corrida, de modo que el costo computacional pueda analizarse al aumentar el tamaño de las instancias. Los controles y registros permitirán examinar el riesgo de atribuir al aprendizaje mejoras debidas a un mayor presupuesto o a la reparación de candidatos.

3. Configuración experimental

Este diseño responde a la pregunta del proyecto: ¿en qué condiciones D-MAB mejora Tabu Search frente a la selección uniforme? Por ello, las comparaciones comparten representación, planificador, objetivo y presupuesto. La hipótesis primaria plantea que, bajo congestión, Tabu con D-MAB obtiene menor f medio que Tabu uniforme. El equipo fijó hipótesis, semillas y pruebas en un protocolo previo a los experimentos nuevos. Esta sección actualiza el plan de evaluación de la sección anterior y prevalece ante cualquier diferencia. Además, describe el diseño y no informa conclusiones.

3.1. Conjuntos de datos

El estudio usa dos catálogos sintéticos, sin datos clínicos, y los analiza por separado. El catálogo estándar proviene del repositorio oficial (Saicooh, 2026). Contiene 12 instancias: tres réplicas de 15, 20, 25 y 30 cirugías. Sin embargo, este catálogo casi no tensiona la espera entre etapas. Solo 16 de 240 soluciones finales del estudio de carteras presentan espera positiva. Por tanto, no permite evaluar la condición de bloqueo que plantea la pregunta.

Para cubrir ese vacío, el equipo generó un catálogo de congestión de 48 instancias, doce por tamaño. El generador remuestrea pacientes de una instancia estándar y aplica ruido lognormal con $\sigma = 0{,}10$. Luego redondea los tiempos a 0,5 minutos y redibuja la elegibilidad de personal. Cada instancia tiene semilla propia.

Una calibración evaluó 18 combinaciones de salas, cirujanos y espera máxima, sobre cuatro instancias de desarrollo excluidas del catálogo. La regla pre-registrada eligió reducir los cirujanos al 40 % y mantener salas y espera máxima. Esta elección sigue el mecanismo del modelo: con la misma sala en ambas etapas, la espera depende del cirujano. De hecho, sin reducir cirujanos, ninguna combinación superó 10 % de soluciones con espera. En el catálogo final, 51,8 % de las soluciones de Tabu uniforme y D-MAB presenta espera positiva. Este dato verifica la presión sobre la restricción.

Ambos catálogos superan la validación de esquema, tiempos, recursos, elegibilidad y digest canónico. Además, FIFO, SPT y LPT encuentran solución factible en las 48 instancias nuevas. Los manifiestos guardan el SHA-256 de cada archivo. Cada experimento usa un rango exclusivo de semillas. Las semillas nuevas sobre el catálogo estándar miden variación de la búsqueda; no miden generalización a instancias no vistas.

3.2. Líneas base y controles

La Tabla 2 vincula cada control con la explicación alternativa que descarta. Así, una diferencia observada puede atribuirse al aprendizaje y no a otro componente del diseño.

3.3. Métricas

La métrica primaria es $f(S)$ de la ecuación (2), fijada antes de evaluar. Las métricas secundarias son $C_{\text{máx}}$, espera total, espera máxima, factibilidad, tiempo de pared y convergencia. La convergencia se mide con la evaluación de la última mejora global. Estas métricas son descriptivas. Una baja de f no implica una baja de cada componente; por eso, se informan por separado.

Tabla 2: Controles y explicación alternativa que descarta cada uno.

Control (evaluaciones)	Explicación alternativa
FIFO, SPT y LPT	Una regla constructiva basta. Integran el inicio de Tabu; superarlas no prueba el aporte de D-MAB.
Tabu uniforme (3.030)	La mejora proviene de Tabu y no de aprender.
Tabu prolongado (6.060)	La cartera mejora solo por consumir más evaluaciones.
Dos Tabu independientes (6.060)	La cartera mejora por repetir la búsqueda.
Tabu + UCB1 sin Page–Hinkley (3.030)	El efecto proviene de UCB1 y no del reinicio.

3.4. Implementación

El código usa Python 3.13.2, NumPy 2.2.3, SciPy 1.15.2 y PyYAML 6.0.3. Los experimentos nuevos corren en un AMD Ryzen 7 8845HS, con 8 núcleos, 16 hilos y 13,8 GiB de RAM, sobre Windows 11. La Tabla 3 fija los parámetros. El tiempo se mide en un solo proceso. Una cartera tarda, en mediana, 4,12 s con 15 cirugías (rango 3,83–4,80) y 13,09 s con 30 (rango 12,65–13,53). Sin embargo, el rendimiento varió entre sesiones: con 15 cirugías pasó de 1.470 a cerca de 2.240 evaluaciones por segundo. Por eso, el control principal de cómputo son las evaluaciones.

Tabla 3: Parámetros congelados de la búsqueda y del presupuesto.

Componente	Configuración
Tabu	30 soluciones iniciales (FIFO, SPT, LPT y 27 aleatorias); lotes de 15 candidatos; memoria de 7 firmas de solución; aspiración por mejora global.
D-MAB	Brazos `swap`, `insert`, `room_1`, `room_2` y `room_pair`; $C = 0{,}1$; $\delta = 0{,}01$; $\lambda = 1$.
Cartera	Dos caminos de 3.030 evaluaciones; reparto 50/50 fijo; conserva el menor f.
Parada	Agotar el presupuesto de evaluaciones del camino.
Conteo	Cuentan las 30 iniciales y cada candidato distinto del lote, aun infactible. No cuentan duplicados, reparación ni revalidación final.

El archivo de 30 soluciones del código no altera la trayectoria: retirarlo dejó idénticas 120 corridas de diagnóstico. Por tanto, esas soluciones solo aportan el punto de partida. Para reproducir el estudio, cada carpeta guarda un manifiesto con parámetros, semillas, entorno y hashes de código e instancias. Además, un verificador recalcula cada calendario final con el planificador estricto.

3.5. Corridas y análisis estadístico

El diseño es emparejado: cada método recibe la misma instancia y semilla. El estudio de congestión usa 48 instancias y 20 semillas, es decir, 960 pares por método. Cada par ejecuta cuatro trayectorias y reutiliza el prefijo de Tabu uniforme. Por tanto, las alternativas de un mismo par no son independientes.

La familia confirmatoria tiene cuatro comparaciones. C1 compara D-MAB con Tabu uniforme

y constituye la hipótesis primaria. C2 compara la cartera con Tabu prolongado, y C3 la compara con dos Tabu. C4 compara D-MAB con UCB1. C1 y C4 usan 3.030 evaluaciones; C2 y C3 usan 6.060. Cada diferencia se calcula como alternativa menos referencia. Por tanto, un valor negativo favorece a la alternativa.

Las semillas de una instancia comparten datos. Por eso, la prueba de Wilcoxon bilateral opera sobre medias por instancia y no sobre pares. Holm corrige las cuatro comparaciones. Un bootstrap jerárquico de instancias y semillas, con 5.000 réplicas, entrega intervalos de 95 %. El umbral práctico es 0,25 unidades de f. Todos los tiempos son múltiplos de 0,5 minutos, y un paso de espera total mueve f en 0,25. La hipótesis primaria exige p de Holm menor que 0,05, intervalo bajo cero y media de a lo sumo $-0{,}25$.

Tabla 4: Tamaños para potencia 0,80 y $\alpha = 0{,}05$, según diferencias de 240 pares. DE: desviación estándar de la diferencia.

		Pares necesarios		Instancias (20 semillas)	
Comparación	DE	Efecto 0,25	Efecto 0,65	Efecto 0,25	Efecto 0,65
D-MAB − Tabu uniforme	7,034	6.217	922	317	49
Cartera − Tabu prolongado	4,292	2.315	345	221	35
Cartera − Dos Tabu	5,018	3.165	470	322	50

La Tabla 4 justifica el número de corridas con los datos del estudio de carteras. El diseño de 240 pares está subdimensionado: C1 necesita 922 pares para detectar 0,65 y 6.217 para detectar 0,25. Son 3,8 y 25,9 veces los pares disponibles. Además, con 12 instancias, la potencia simulada de la prueba real es 0,30 y 0,08, respectivamente. Por esta razón, una regla pre-registrada fijó 48 instancias. Con ese tamaño, C1 alcanza 0,87 para detectar 0,65. Sin embargo, baja a 0,72 con $\alpha = 0{,}0125$, el peor caso de Holm, y a 0,24 para detectar 0,25. Por tanto, un resultado no significativo no probará equivalencia. Finalmente, un piloto descriptivo de 40 corridas prueba el protocolo con igual tiempo de pared, porque los demás estudios igualan evaluaciones.

3.6. Amenazas a la validez

Cinco amenazas limitan la interpretación. Primero, la reparación altera cerca de un tercio de los candidatos (31,3 %). Así, la recompensa se atribuye a un movimiento que no se aplicó tal cual. Segundo, solo 3,9 % de las propuestas recibe recompensa positiva, lo que reduce la señal para aprender. Tercero, las instancias estándar ya eran conocidas al elegir la arquitectura. Cuarto, el catálogo de congestión comparte el perfil de duraciones del estándar y no constituye un dominio independiente. Quinto, la potencia simulada supone un efecto homogéneo y extrapola desde 12 instancias. Además, la DE de C1 en congestión fue 13,21, frente a la DE supuesta de 7,03. Con la aproximación t, la DE supuesta pedía 49 instancias para potencia 0,80. Con la DE observada, 48 instancias alcanzan 0,32.

4. Conclusión

La arquitectura propuesta sitúa el aprendizaje en la evolución de Tabu Search, al utilizar D-MAB para seleccionar los movimientos que generan nuevos vecinos y una cartera fija para conservar el mejor calendario factible entre el camino uniforme y el adaptativo. Con ello, se establece una metodología reproducible para estudiar si la adaptación contribuye a reducir el makespan y el bloqueo, manteniendo estrictas las restricciones del problema.

La evaluación se organizará para distinguir el aporte del aprendizaje del efecto de repetir la búsqueda y del presupuesto computacional, evitando atribuir al controlador ventajas que correspondan a otros componentes. También se analizará cómo la reparación de candidatos influye en la utilidad observada de los movimientos. A lo largo del semestre se ampliarán las pruebas a escenarios reservados y de mayor congestión, con el propósito de determinar cuándo conviene utilizar la propuesta, qué costo implica y cuáles son sus límites al aumentar la escala.

REFERENCIAS

Akbarzadeh, B., & Maenhout, B. (2024). A two-layer heuristic for patient sequencing in the operating room theatre considering multiple resource phases. *Computers & Operations Research*, *170*, 106768. https://doi.org/10.1016/j.cor.2024.106768

DaCosta, L., Fialho, A., Schoenauer, M., & Sebag, M. (2008). Adaptive operator selection with dynamic multi-armed bandits. *Proceedings of the Genetic and Evolutionary Computation Conference*, 913-920. https://doi.org/10.1145/1389095.1389272

Dolatkhah, M., Hashemi Doulabi, H., Rei, W., & Gendreau, M. (2026, 24 de abril). *A reinforcement-learning-based column generation algorithm for integrated operating room planning and scheduling* [Preprint, versión 1]. arXiv: 2604.22977. https://doi.org/10.48550/arXiv.2604.22977

Lara Arce, J. (2026, agosto). *Programación de cirugías electivas* [Material de clase, OII464].

Niroumandrad, N., Lahrichi, N., & Lodi, A. (2024). Learning tabu search algorithms: A scheduling application. *Computers & Operations Research*, *170*, 106751. https://doi.org/10.1016/j.cor.2024.106751

Saicooh. (2026). *OII464_Hospitales* [Repositorio docente de código e instancias]. https://github.com/Saicooh/OII464_Hospitales

Vega, E. (s.f.). *Taxonomía ML → MH (visión general)* [Material de clase de OII464, diapositiva 6].

Yin, D., Wang, J., Wang, Y., & Punnen, A. (2026). Multi-operator driven iterated tabu search for inter-hospital operating room scheduling. *Journal of the Operational Research Society*, *77*(9), 2606-2626. https://doi.org/10.1080/01605682.2025.2554741

Yu, H., Gao, K.-Z., Wu, N., & Suganthan, P. N. (2024). Ensemble meta-heuristics and Q-learning for staff dissatisfaction constrained surgery scheduling and rescheduling. *Engineering Applications of Artificial Intelligence*, *134*, 108668. https://doi.org/10.1016/j.engappai.2024.108668