ESCUELA DE INGENIERÍA INFORMÁTICA



PONTIFICIA UNIVERSIDAD CATÓLICA DE VALPARAÍSO

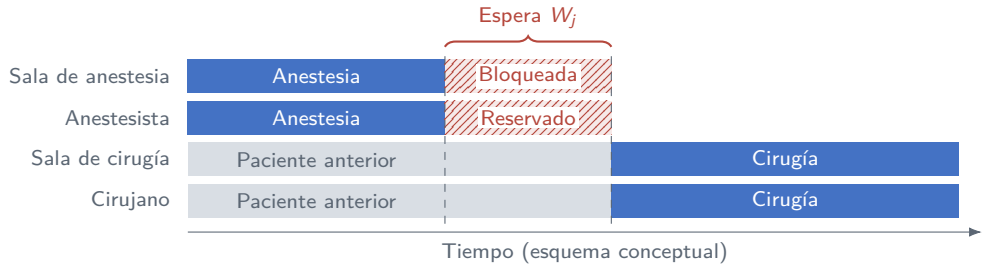
Programación de cirugías electivas mediante búsqueda tabú y selección adaptativa de movimientos

Entrega 2: configuración experimental

José Basualto · Cristopher Dauros · Carlos Ruz

OII464: Desarrollo de Diseños Híbridos para Optimización · Prof. Emanuel Vega · 2 de noviembre de 2026

Mientras un paciente espera, su sala y su anestesista quedan bloqueados



- La anestesia termina, pero la sala de cirugía sigue ocupada.
- La primera sala y el anestesista quedan retenidos hasta el traslado.
- Ese bloqueo retrasa a los pacientes siguientes y alarga la jornada.

El calendario debe terminar antes sin exceder la espera máxima

- Cada paciente pasa por anestesia y luego por cirugía.
- Salas y personal son compartidos; el planificador asigna profesionales elegibles.
- Restricción estricta: la espera nunca supera `max_wait`.
- Minimizamos un objetivo combinado, sin penalizar desequilibrio de salas.

$$f(S) = \underbrace{C_{\max}}_{\text{fin de la jornada}} + \underbrace{10^{-6} \sum_{o} t_o^{\text{ini}}}_{\text{desempate}} + \underbrace{0{,}5 \sum_{j} W_j}_{\text{espera total}} + \underbrace{1{,}4 \max_{j} W_j}_{\text{peor espera}}$$

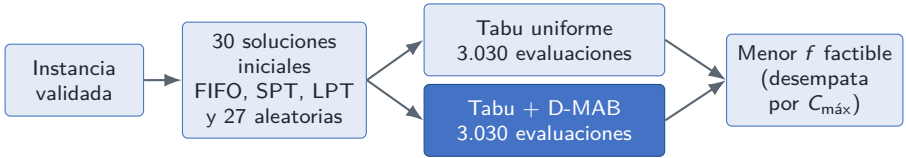
Falta medir si D-MAB aporta a Tabu con espera estricta

- Yu et al. (2024): Q-learning en programación quirúrgica.
- Dolatkhah et al. (2026, preprint): D-MAB dentro de un genético.
- Yin et al. (2026): Tabu multioperador entre hospitales.
- Nicho: D-MAB en Tabu, dos etapas, espera estricta y reparación.

Pregunta de investigación

¿En qué condiciones la selección adaptativa de movimientos mediante D-MAB mejora la calidad, el tiempo o la robustez de Tabu Search frente a elegir los mismos movimientos uniformemente?

Una cartera fija corre dos caminos y conserva el mejor calendario



ML: fase de evolución

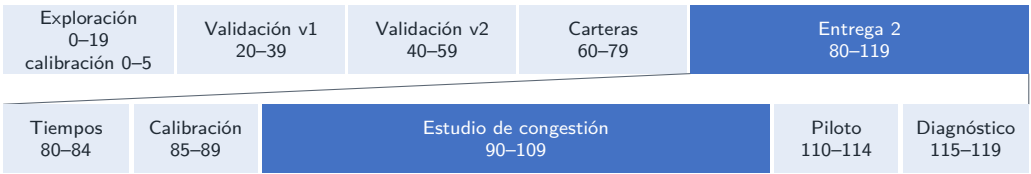
- ML actúa en la fase de evolución: elige cada movimiento.
- Reparto 50/50 y selección final son deterministas.
- No empeora el Tabu de 3.030 de su semilla; gasta el doble.

D-MAB aprende en línea qué movimiento proponer a Tabu

$$a_t = \arg\max_a \left[\bar{r}_a + C\sqrt{\frac{2\ln t}{n_a}} \right], \qquad C = 0{,}1$$

- Cinco brazos: `swap`, `insert`, `room_1`, `room_2`, `room_pair`.
- Recompensa: mejora del candidato frente al estado local previo.
- Normalizada por 2 % del objetivo inicial, entre 0 y 1.
- Page–Hinkley detecta caídas y reinicia solo estadísticas del bandido.
- Aprende dentro de cada corrida, sin entrenamiento previo.

Las etapas usan semillas separadas y el protocolo quedó registrado antes



- Datos sintéticos: 12 instancias estándar y 48 de congestión.
- Protocolo registrado en el commit a0da669, antes de ejecutar.
- Cada estudio guarda manifiesto con hashes de código e instancias.
- Semillas nuevas en un mismo catálogo no miden generalización.

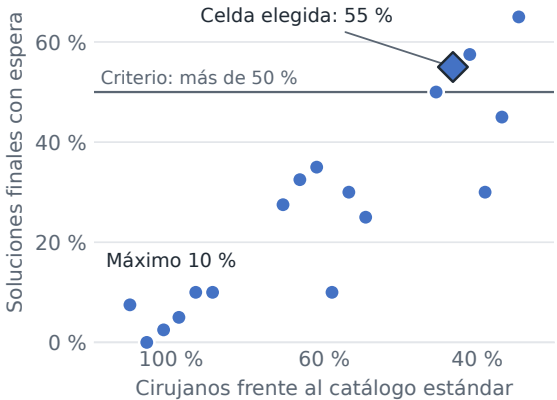
Cuatro comparaciones separan aprendizaje, cómputo y repetición de la búsqueda

Id	Comparación (evaluaciones)	Explicación alternativa que descarta
C1	D-MAB − Tabu uniforme (3.030)	La mejora viene de Tabu, no de aprender
C2	Cartera − Tabu prolongado (6.060)	La cartera mejora solo por más evaluaciones
C3	Cartera − Dos Tabu (6.060)	La cartera mejora por repetir la búsqueda
C4	D-MAB − UCB1 sin Page–Hinkley (3.030)	El efecto viene de UCB1, no del reinicio

Líneas base: FIFO, SPT y LPT, que también integran el inicio de Tabu.

- Primaria: f. Secundarias: $C_{\text{máx}}$, espera, factibilidad, tiempo, convergencia.
- Wilcoxon sobre medias por instancia, Holm sobre C1–C4, bootstrap jerárquico.
- Signo: alternativa − referencia; negativo favorece a la alternativa.
- Umbral práctico: 0,25 unidades de f.

El catálogo original no ejercía presión sobre la espera



- Catálogo estándar: solo 16 de 240 soluciones con espera.
- Reducir salas o `max_wait` dejó 10 % o menos.
- Reducir cirujanos al 40 % alcanzó 55 % en desarrollo.
- Con igual sala, la espera depende del cirujano.
- Catálogo final: 48 instancias nuevas, 51,8 % con espera.

240 pares no podían detectar el efecto; la regla previa fijó 960

Planificación, catálogo estándar

922 pares

para detectar 0,65 con DE 7,03; había 240

Regla pre-registrada

960 pares

48 instancias por 20 semillas

Congestión, DE real 13,21

Potencia 0,32

aproximación t para detectar 0,65; harían falta 3.246 pares

- Con 12 instancias, la potencia simulada para 0,65 era 0,30.
- Con DE 7,03 y aproximación t, bastaban 49 instancias para 0,80.
- No ampliamos la muestra: el protocolo prohíbe hacerlo tras ver resultados.

El diseño fija de antemano cómo atribuir una mejora al aprendizaje

Qué fija este diseño

- Dos catálogos: 12 estándar y 48 de congestión.
- Cinco controles con igual presupuesto de evaluaciones.
- Hipótesis, semillas y regla de decisión registradas antes.

Qué viene

- Informar los resultados de C1–C4 en la próxima entrega.
- Evaluar igual tiempo, instancias no vistas y mayor escala.

Apéndice: la configuración quedó congelada antes de ejecutar

Componente	Configuración
Tabu	30 soluciones iniciales (FIFO, SPT, LPT y 27 aleatorias); lotes de 15 candidatos; memoria de 7 firmas de solución; aspiración por mejora global.
D-MAB	Cinco brazos; $C = 0{,}1$; $\delta = 0{,}01$; $\lambda = 1$.
Cartera	Dos caminos de 3.030 evaluaciones; reparto 50/50 fijo; conserva el menor f.
Parada	Agotar el presupuesto de evaluaciones del camino.
Conteo	Cuentan las 30 iniciales y cada candidato distinto del lote, aun infactible. No cuentan duplicados, reparación ni revalidación final.
Entorno	AMD Ryzen 7 8845HS, 8 núcleos, 13,8 GiB; Python 3.13.2, NumPy 2.2.3, SciPy 1.15.2.